PROBABILITÉS ET STATISTIQUES 1

IV. Suites de variables aléatoires

Kamel ATTAR

Exercice 1 — **Convergence L_2 et en proba vers 0**

Pour chacune des suites (X_n) suivantes :

- Déterminer si $(X_n) \xrightarrow{L_2} 0$.
- Déterminer si $(X_n) \xrightarrow{\text{prob}} 0$.

❶ (X_n) est une suite de variables aléatoires telle que pour tout $n \in \mathbb{N}^*$, $X_n \rightsquigarrow \text{Unif}\left(\frac{1}{n}, \frac{2}{n}\right)$.

❷ (X_n) est une suite de variables aléatoires telle que pour tout $n \in \mathbb{N}^*$, $X_n \rightsquigarrow \text{Exp}(n)$.

❸ (X_n) est une suite de variables aléatoires telle que pour tout $n \in \mathbb{N}^*$, $X_n \rightsquigarrow \mathcal{N}\left(m=\frac{1}{n}, \sigma^2=\frac{1}{n^2}\right)$.

❹ (X_n) est une suite de variables aléatoires telle que pour tout $n \in \mathbb{N}^*$,

$$X_n = \begin{cases} n & \text{avec la probabilité } \frac{1}{n} \\ 0 & \text{avec la probabilité } 1 - \frac{1}{n} \end{cases}$$

Solution :

❶ On suppose que $X_n \rightsquigarrow \text{Unif}\left(\frac{1}{n}, \frac{2}{n}\right)$.

- **Convergence dans L_2.**
  Pour une variable aléatoire $X \rightsquigarrow \text{Unif}(a, b)$, on sait que

$$\mathrm{E}(X) = \frac{a+b}{2}, \qquad \mathrm{Var}(X) = \frac{(b-a)^2}{12}.$$

  Ainsi,

$$\mathrm{E}(X_n) = \frac{3}{2n}, \qquad \mathrm{Var}(X_n) = \frac{1}{12n^2}.$$

  Par conséquent,

$$\begin{aligned} \mathrm{E}(X_n^2) &= \mathrm{Var}(X_n) + \left(\mathrm{E}(X_n)\right)^2 \\ &= \frac{1}{12n^2} + \frac{9}{4n^2} \\ &= \frac{7}{3n^2} \xrightarrow[n\to+\infty]{} 0. \end{aligned}$$

  Donc $(X_n) \xrightarrow{L_2} 0$.
- **Convergence en probabilité.**
  La fonction de répartition de X_n est

$$F_{X_n}(x) = \begin{cases} 0, & x < \frac{1}{n}, \\ nx - 1, & \frac{1}{n} \le x \le \frac{2}{n}, \\ 1, & x > \frac{2}{n}. \end{cases}$$

Fixons $\varepsilon > 0$. Comme la loi uniforme est continue,

$$\mathbb{P}(-\varepsilon < X_n < \varepsilon) = F_{X_n}(\varepsilon) - F_{X_n}(-\varepsilon).$$

Puisque $\varepsilon > 0$, on a $F_{X_n}(-\varepsilon) = 0$. De plus,

$$\frac{2}{n} \xrightarrow[n\to+\infty]{} 0.$$

Ainsi, pour tout $\varepsilon > 0$ fixé, on a $\frac{2}{n} < \varepsilon$ lorsque n est suffisamment grand. Il en résulte que $F_{X_n}(\varepsilon) = 1$, et donc

$$\mathbb{P}(-\varepsilon < X_n < \varepsilon) = 1$$

à partir d'un certain rang.
Par conséquent,

$$\mathbb{P}(-\varepsilon < X_n < \varepsilon) \xrightarrow[n\to+\infty]{} 1.$$

Ainsi, $(X_n) \xrightarrow{\text{prob}} 0$.

En utilisant la définition de la limite Soit $\varepsilon \in]0,1[$, cherchons $N(\varepsilon) \geq 0$ telle que, pour tout $n \geq N(\varepsilon)$, $P(|X_n - X| < \varepsilon) = 1$. On a

$$P(|X_n - X| < \varepsilon) = P(|X_n| < \varepsilon) = P(X_n < \varepsilon) = F_{X_n}(\varepsilon).$$

On sait que $F_{X_n}(\varepsilon) = 1$, $\forall \varepsilon \geq \frac{2}{n}$. Alors on choisit $N(\varepsilon) = \frac{2}{\varepsilon}$.
Ainsi, pour tout $\varepsilon > 0$, il existe $N(\varepsilon) = \frac{2}{\varepsilon}$, telle que $\forall n \geq N(\varepsilon)$, on a

$$n \geq \frac{2}{\varepsilon} \Longrightarrow \frac{2}{n} \leq \varepsilon \Longrightarrow \left[\frac{1}{n}, \frac{2}{n}\right] \subset]-\varepsilon, \varepsilon[\Longrightarrow P(|X_n| < \varepsilon) = 1$$

Soit encore : $(X_n) \xrightarrow{\text{prob}} 0$.

❷ On suppose que $X_n \rightsquigarrow \text{Exp}(n)$, où n est le paramètre de taux.

- **Convergence dans L_2.**
  Pour une variable aléatoire $X \rightsquigarrow \text{Exp}(\lambda)$, on sait que

  $$\text{E}(X) = \frac{1}{\lambda}, \qquad \text{Var}(X) = \frac{1}{\lambda^2}.$$

  Par conséquent,

  $$\begin{aligned} \text{E}(X_n^2) &= \text{Var}(X_n) + \big(\text{E}(X_n)\big)^2 \\ &= \frac{1}{n^2} + \frac{1}{n^2} \\ &= \frac{2}{n^2} \xrightarrow[n\to+\infty]{} 0. \end{aligned}$$

  Donc $(X_n) \xrightarrow{L_2} 0$.
- **Convergence en probabilité.**
  La fonction de répartition de X_n est

  $$F_{X_n}(x) = \begin{cases} 0, & x < 0, \\ 1 - e^{-nx}, & x \geq 0. \end{cases}$$

  Fixons $\varepsilon > 0$. La loi exponentielle étant continue,

  $$\begin{aligned} \mathbb{P}(-\varepsilon < X_n < \varepsilon) &= F_{X_n}(\varepsilon) - F_{X_n}(-\varepsilon) \\ &= (1 - e^{-n\varepsilon}) - 0 \\ &= 1 - e^{-n\varepsilon}. \end{aligned}$$

Puisque $\varepsilon > 0$ est fixé, on a

$$n\varepsilon \xrightarrow[n\to+\infty]{} +\infty.$$

Par conséquent,

$$e^{-n\varepsilon} \xrightarrow[n\to+\infty]{} 0.$$

Ainsi,

$$\mathbb{P}(-\varepsilon < X_n < \varepsilon) \xrightarrow[n\to+\infty]{} 1.$$

Donc $(X_n) \xrightarrow{\text{prob}} 0$.

En utilisant la définition de la limite Soit $\varepsilon \in]0,1[$, cherchons $N(\varepsilon) \geq 0$ telle que, pour tout $n \geq N(\varepsilon)$, $P(|X_n| < \varepsilon) = 1$. Pour tout $\varepsilon > 0$, on a

$$P(|X_n| < \varepsilon) = P(X_n < \varepsilon) = F_{X_n}(\varepsilon) = 1 - e^{-n\varepsilon}\,.$$

Cherchons $N(\varepsilon)$, telle que

$$1 - e^{-n\varepsilon} = 1 \quad \Longleftrightarrow \quad e^{-n\varepsilon} = 0 \quad \Longleftrightarrow \quad n\varepsilon >> 1 \quad \Longleftrightarrow \quad n >> \frac{1}{\varepsilon}\,.$$

Ainsi, pour tout $\varepsilon > 0$, il existe $N(\varepsilon) = \lfloor e^{\frac{1}{\varepsilon}} \rfloor >> \frac{1}{\varepsilon}$, telle que $\forall n \geq N(\varepsilon)$, on a

$$n >> \frac{1}{\varepsilon} \quad \Longrightarrow \quad 1 - e^{-n\varepsilon} = 1 \quad \Longrightarrow \quad P(|X_n| < \varepsilon) = 1\,.$$

Donc $(X_n) \xrightarrow{\text{prob}} 0$.

❸ On suppose que

$$X_n \rightsquigarrow \mathcal{N}\left(\frac{1}{n}, \frac{1}{n^2}\right),$$

où le deuxième paramètre désigne la variance.

- **Convergence dans L_2.**
  On a
  $$\mathrm{E}(X_n) = \frac{1}{n}, \qquad \mathrm{Var}(X_n) = \frac{1}{n^2}.$$
  Ainsi,
  $$\begin{aligned}\mathrm{E}(X_n^2) &= \mathrm{Var}(X_n) + \big(\mathrm{E}(X_n)\big)^2 \\ &= \frac{2}{n^2} \xrightarrow[n\to+\infty]{} 0.\end{aligned}$$
  Donc $(X_n) \xrightarrow{L_2} 0$.
- **Convergence en probabilité.**
  Notons Φ la fonction de répartition de la loi normale centrée réduite $\mathcal{N}(0,1)$.
  La fonction de répartition de X_n est
  $$F_{X_n}(x) = \Phi\left(\frac{x - \frac{1}{n}}{\frac{1}{n}}\right) = \Phi(nx - 1).$$
  Fixons $\varepsilon > 0$. La loi normale étant continue,
  $$\begin{aligned}\mathbb{P}(-\varepsilon < X_n < \varepsilon) &= F_{X_n}(\varepsilon) - F_{X_n}(-\varepsilon) \\ &= \Phi(n\varepsilon - 1) - \Phi(-n\varepsilon - 1).\end{aligned}$$
  Puisque $\varepsilon > 0$ est fixé,
  $$n\varepsilon - 1 \xrightarrow[n\to+\infty]{} +\infty$$
  et
  $$-n\varepsilon - 1 \xrightarrow[n\to+\infty]{} -\infty.$$

Or,

$$\lim_{x\to+\infty}\Phi(x)=1, \qquad \lim_{x\to-\infty}\Phi(x)=0.$$

Par conséquent,

$$\mathbb{P}(-\varepsilon<X_n<\varepsilon)\xrightarrow[n\to+\infty]{}1.$$

Donc $(X_n)\xrightarrow{\text{prob}}0$.

En utilisant la définition de la limite Soit $\varepsilon\in]0,1[$,

$$P(|X_n|<\varepsilon)=P(-n\varepsilon-1<Z_n<n\varepsilon-1)=\Phi(n\varepsilon-1)-\Phi(-n\varepsilon-1)$$

Posons $N(\varepsilon)=\lfloor e^{\frac{1}{\varepsilon}}\rfloor >> \frac{1}{\varepsilon}$. Pour tout $n\geq N(\varepsilon)$. On a

* $(n\varepsilon-1)>>1 \iff (n\varepsilon-1)\xrightarrow[n\to+\infty]{}+\infty$
* $(n\varepsilon+1)>>1 \iff (-n\varepsilon-1)\xrightarrow[n\to+\infty]{}-\infty$

On tire $\Phi(-n\varepsilon-1)\xrightarrow[n\to+\infty]{}0$ et $\Phi(n\varepsilon-1)\xrightarrow[n\to+\infty]{}1$.

❹ Pour tout $n\geq 1$, la variable X_n est définie par

$$X_n=\begin{cases}n, & \text{avec probabilité } \frac{1}{n},\\ 0, & \text{avec probabilité } 1-\frac{1}{n}.\end{cases}$$

- **Convergence dans L_2.**
  On a
  $$\begin{aligned}\mathrm{E}(X_n^2)&=n^2\frac{1}{n}+0^2\left(1-\frac{1}{n}\right)\\&=n.\end{aligned}$$
  Comme
  $$\mathrm{E}(X_n^2)=n\xrightarrow[n\to+\infty]{}+\infty,$$
  la suite (X_n) ne converge pas vers 0 dans L_2.
- **Convergence en probabilité.**
  Fixons $\varepsilon>0$. Dès que $n>\varepsilon$, la valeur n est strictement supérieure à ε. Puisque X_n ne prend que les valeurs 0 et n, on obtient
  $$\begin{aligned}\mathbb{P}(-\varepsilon<X_n<\varepsilon)&=\mathbb{P}(X_n=0)\\&=1-\frac{1}{n}.\end{aligned}$$
  Par conséquent,
  $$\mathbb{P}(-\varepsilon<X_n<\varepsilon)\xrightarrow[n\to+\infty]{}1.$$
  Ainsi, $(X_n)\xrightarrow{\text{prob}}0$.

Exercice 2 $\max(X_1, \cdots, X_n)$

Soit (X_n) une suite de variables aléatoires indépendantes, telle que pour tout $n \in \mathbb{N}^*$, $X_n \rightsquigarrow \text{Exp}(1)$.

Considérons la suite (Y_n) définie par : $Y_n = \max(X_1, \cdots, X_n)$.

On se propose de montrer que $\left(\frac{Y_n}{\ln(n)}\right) \xrightarrow{\text{prob}} 1$.

❶ Déterminer la fonction de répartition de Y_n. On note F_n cette fonction.

❷ Soit $\varepsilon \in]0,1[$. En utilisant la fonction F_n, montrer que pour tout $n \geqslant 2$,

$$P\left(\left|\frac{Y_n}{\ln(n)} - 1\right| < \varepsilon\right) = \left(1 - \frac{1}{n^{1+\varepsilon}}\right)^n - \left(1 - \frac{1}{n^{1-\varepsilon}}\right)^n$$

❸ En déduire que $P\left(\left|\frac{Y_n}{\ln(n)} - 1\right| < \varepsilon\right) \xrightarrow[n\to+\infty]{} 1$.

Indication : Étudier la limite de $\left(1 - \frac{1}{n^a}\right)^n$ *selon la valeur de* $a \in]0, +\infty[$.

- *Montrer que si* $a > 1$, *alors* $\left(1 - \frac{1}{n^a}\right)^n \to 1$.
- *Montrer que si* $0 < a < 1$, *alors* $\left(1 - \frac{1}{n^a}\right)^n \to 0$.

Solution :

❶ $F_n(x) = P(Y_n \leqslant x) = P(X_1 \leqslant x \text{ et } \cdots \text{ et } X_n \leqslant x)$

Comme les variables $X_1, \cdots, X_n$ sont indépendantes, on peut écrire

$$F_n(x) = P(X_1 \leqslant x) \times \cdots \times P(X_n \leqslant x) = F^n(x)$$

où F est la fonction de répartition de chaque variable X_k. Mais alors :

$$F(x) = \left| \begin{array}{ll} 1 - e^{-x} & \text{si } x \geqslant 0 \\ 0 & \text{sinon} \end{array} \right. \quad \Longrightarrow \quad F_n(x) = \left| \begin{array}{ll} (1 - e^{-x})^n & \text{si } x \geqslant 0 \\ 0 & \text{sinon} \end{array} \right.$$

❷ $P\left(\left|\frac{Y_n}{\ln(n)} - 1\right| < \varepsilon\right) = P\left(1 - \varepsilon < \frac{Y_n}{\ln(n)} < 1 + \varepsilon\right) = P\Big((1-\varepsilon)\ln(n) < Y_n < (1+\varepsilon)\ln(n)\Big)$

Donc $P\left(\left|\frac{Y_n}{\ln(n)} - 1\right| < \varepsilon\right) = F_n\Big(\ln n^{(1+\varepsilon)}\Big) - F_n\Big(\ln n^{(1-\varepsilon)}\Big)$

En utilisant l'expression de F_n obtenue question ❶, on obtient

$$P\left(\left|\frac{Y_n}{\ln(n)} - 1\right| < \varepsilon\right) = \left(1 - e^{-\ln n^{(1+\varepsilon)}}\right)^n - \left(1 - e^{-\ln n^{(1-\varepsilon)}}\right)^n = \left(1 - \frac{1}{n^{1+\varepsilon}}\right)^n - \left(1 - \frac{1}{n^{1-\varepsilon}}\right)^n$$

❸ On utilise la limite fondamentale :

$$\left(1 - \frac{1}{n^a}\right)^n = e^{n\ln\left(1-\frac{1}{n^a}\right)} = e^{n\left[-\frac{1}{n^a} + o\left(\frac{1}{n^a}\right)\right]} = e^{-n^{1-a} + o\left(n^{1-a}\right)} \longrightarrow \begin{cases} 1 & \text{si } a > 1 \\ 0 & \text{si } a < 1 \end{cases}$$

On considère :

$$P\left(\left|\frac{Y_n}{\ln(n)} - 1\right| < \varepsilon\right) = \left(1 - \frac{1}{n^{1+\varepsilon}}\right)^n - \left(1 - \frac{1}{n^{1-\varepsilon}}\right)^n$$

- **Premier terme :** $\left(1 - \frac{1}{n^{1+\varepsilon}}\right)^n \longrightarrow 1 \quad \text{car } 1 + \varepsilon > 1$

- **Deuxième terme :** $\left(1-\frac{1}{n^{1-\varepsilon}}\right)^n \longrightarrow 0 \quad \text{car } 1-\varepsilon<1$

Conclusion

$$P\left(\left|\frac{Y_n}{\ln(n)}-1\right|<\varepsilon\right) = \underbrace{\longrightarrow 1}_{\text{1er terme}} - \underbrace{\longrightarrow 0}_{\text{2e terme}} \qquad \Longrightarrow \qquad P\left(\left|\frac{Y_n}{\ln(n)}-1\right|<\varepsilon\right) \xrightarrow[n\to\infty]{} 1$$

Exercice 3 — **Intervalles de confiance**

On lance un dé équilibré de manière indépendante plusieurs fois et on compte le nombre de lancers dont le résultat est égal à 1. Pour tout $n \in \mathbb{N}^*$, on note

$\overline{X}_n$ la fréquence d'apparition du résultat 1 au cours des n premiers lancers.

❶ Justifier que

$$\left(\overline{X}_n\right) \xrightarrow{\text{p.s.}} \frac{1}{6}.$$

❷ Soit $n \in \mathbb{N}^*$. En utilisant l'inégalité de Tchebychev, déterminer un intervalle $[a_n, b_n]$ centré en $\frac{1}{6}$ tel que

$$P\left(\overline{X}_n \in [a_n, b_n]\right) \geqslant 0.95.$$

❸ On suppose que n est suffisamment grand. En utilisant le théorème central limite, déterminer un intervalle $[a'_n, b'_n]$ centré en $\frac{1}{6}$ tel que

$$P\left(\overline{X}_n \in [a'_n, b'_n]\right) \simeq 0.95.$$

❹ Comparer les deux intervalles obtenus. Quelle méthode permet d'obtenir l'intervalle le plus précis ?

Solution :

❶ Pour tout $k \in \mathbb{N}^*$, on pose

$$X_k = \begin{cases} 1 & \text{si le résultat du lancer } k \text{ est 1,} \\ 0 & \text{sinon.} \end{cases}$$

Les variables aléatoires $(X_k)_{k\geqslant 1}$ sont indépendantes et identiquement distribuées, de loi $\mathcal{B}\left(\frac{1}{6}\right)$. De plus,

$$\overline{X}_n = \frac{X_1 + \cdots + X_n}{n}.$$

D'après la loi forte des grands nombres,

$$\boxed{\left(\overline{X}_n\right) \xrightarrow{\text{p.s.}} \mathrm{E}(X_1) = \frac{1}{6}.}$$

❷ On a

$$\mathrm{E}(\overline{X}_n) = \frac{1}{6} \qquad \text{et} \qquad \mathrm{Var}(\overline{X}_n) = \frac{\mathrm{Var}(X_1)}{n} = \frac{5}{36n}.$$

D'après l'inégalité de Tchebychev, pour tout $\varepsilon > 0$,

$$P\left(\left|\overline{X}_n - \mathrm{E}\left(\overline{X}_n\right)\right| \geq \varepsilon\right) \leq \frac{\mathrm{Var}\left(\overline{X}_n\right)}{\varepsilon^2} \qquad \Longleftrightarrow \qquad P\left(\left|\overline{X}_n - \mathrm{E}\left(\overline{X}_n\right)\right| < \varepsilon\right) \geqslant 1 - \frac{\mathrm{Var}\left(\overline{X}_n\right)}{\varepsilon^2}$$

Donc

$$P\left(\left|\overline{X}_n - \frac{1}{6}\right| < \varepsilon\right) \geqslant 1 - \frac{5}{36n\varepsilon^2}.$$

On choisit ε de sorte que

$$1 - \frac{5}{36n\varepsilon^2} = 0.95.$$

Ainsi,

$$\varepsilon = \sqrt{\frac{5}{36n \times 0.05}} = \frac{5}{3\sqrt{n}}.$$

Par conséquent, l'intervalle

$$\boxed{[a_n, b_n] = \left[\frac{1}{6} - \frac{5}{3\sqrt{n}}, \frac{1}{6} + \frac{5}{3\sqrt{n}}\right]}$$

vérifie

$$P\left(\overline{X}_n \in [a_n, b_n]\right) \geqslant 0.95.$$

❸ Pour $n \in \mathbb{N}^*$, posons

$$Z_n = \frac{\overline{X}_n - \mathrm{E}\left(\overline{X}_n\right)}{\sigma\left(\overline{X}_n\right)} = \frac{\overline{X}_n - \frac{1}{6}}{\sqrt{\frac{5}{36n}}} = \frac{\overline{X}_n - \frac{1}{6}}{\frac{1}{6}\sqrt{\frac{5}{n}}}$$

D'après le théorème central limite,

$$Z_n \xrightarrow{\mathcal{L}} \mathcal{N}(0,1).$$

Ainsi, pour n suffisamment grand,

$$P(-1.96 \leqslant Z_n \leqslant 1.96) \simeq 0.95.$$

Or,

$$-1.96 \leqslant Z_n \leqslant 1.96 \iff \frac{1}{6} - \frac{1.96}{6}\sqrt{\frac{5}{n}} \leqslant \overline{X}_n \leqslant \frac{1}{6} + \frac{1.96}{6}\sqrt{\frac{5}{n}}.$$

On obtient donc l'intervalle

$$\boxed{[a'_n, b'_n] = \left[\frac{1}{6} - \frac{1.96}{6}\sqrt{\frac{5}{n}}, \frac{1}{6} + \frac{1.96}{6}\sqrt{\frac{5}{n}}\right].}$$

❹ Les demi-largeurs des deux intervalles sont

$$r_n = \frac{5}{3\sqrt{n}} \qquad \text{et} \qquad r'_n = \frac{1.96\sqrt{5}}{6\sqrt{n}}.$$

Or,

$$\frac{1.96\sqrt{5}}{6} < \frac{5}{3}.$$

Ainsi, $r'_n < r_n$, ce qui implique

$$\boxed{[a'_n, b'_n] \subset [a_n, b_n].}$$

L'intervalle obtenu à l'aide du théorème central limite est donc plus étroit : il est plus précis lorsque n est suffisamment grand.

Exercice 4 **Venise**

La ville de Venise s'enfonce peu à peu, à moins que ce soit le niveau de la mer qui monte. On suppose que, chaque année, la baisse d'altitude de la ville exprimée en millimètres est δX telle que

$$\mathrm{E}(\delta X) = 1 \qquad \text{et} \qquad \mathrm{Var}(\delta X) = \frac{1}{9}$$

On suppose de plus que les changements d'altitude sont indépendants d'une année à l'autre et sont identiquement distribués.
Déterminer un intervalle de prédiction à 95% de la baisse totale au bout de 100 ans.

Solution :

- Pour tout $n \in \mathbb{N}^*$, on note Y_n la baisse d'altitude de la ville pendant la n-ième année. D'après les hypothèses, les variables aléatoires $(Y_n)_{n\geqslant 1}$ sont indépendantes et identiquement distribuées, avec
$$\mathrm{E}(Y_n) = 1 \qquad \text{et} \qquad \mathrm{Var}(Y_n) = \frac{1}{9}.$$
- La baisse totale d'altitude au bout de 100 ans est
$$S_{100} = Y_1 + Y_2 + \cdots + Y_{100}.$$
Par linéarité de l'espérance et par indépendance des variables,
$$\mathrm{E}(S_{100}) = 100 \qquad \text{et} \qquad \mathrm{Var}(S_{100}) = \frac{100}{9}.$$
Ainsi,
$$\sigma(S_{100}) = \frac{10}{3}.$$
- On pose
$$Z_{100} = \frac{S_{100} - \mathrm{E}(S_{100})}{\sigma(S_{100})} = \frac{S_{100} - 100}{10/3}.$$
D'après le théorème central limite, pour n suffisamment grand, la variable centrée réduite associée à S_n est approximativement de loi normale centrée réduite. On peut donc écrire
$$P(-1.96 \leqslant Z_{100} \leqslant 1.96) \simeq 0.95.$$
Par conséquent,
$$P\left(-1.96 \leqslant \frac{S_{100} - 100}{10/3} \leqslant 1.96\right) \simeq 0.95.$$
En multipliant par $\frac{10}{3}$ et en ajoutant 100, on obtient
$$P\left(100 - 1.96\frac{10}{3} \leqslant S_{100} \leqslant 100 + 1.96\frac{10}{3}\right) \simeq 0.95.$$
Finalement, un intervalle de prédiction approximatif à 95 % est
$$\boxed{[93.47\,;\,106.53] \text{ mm.}}$$

Exercice 5 **Loi log-normal**

Dans la ville de K., on définit la variable

$$X_n = \text{nombre d'habitants au début de l'année } n$$

en prenant comme référence $n = 0$ l'année 2022.

Les observations passées ont montré que

$$\mathrm{E}\left(\frac{X_{n+1} - X_n}{X_n}\right) = \frac{1}{100} \qquad \text{et} \qquad \sigma\left(\frac{X_{n+1} - X_n}{X_n}\right) = \frac{1}{200}$$

On se propose d'estimer la population à l'année $n = 100$.

❶ Est-il crédible de supposer que les variables $X_{n+1} - X_n$ sont indépendantes et identiquement distribuées ?

❷ Proposer une autre variable pour laquelle pour laquelle cette hypothèse est crédible.

❸ En supposant que $X_0 = 100\,000$, proposer un intervalle $[a_{100}, b_{100}]$ tel que

$$P(X_{100} \in [a_{100}, b_{100}]) \simeq 0.95$$

Solution :

❶ Une augmentation de 1% de X_n conduit à $X_{n+1} - X_n = 0.01\, X_n$ qui dépend de la valeur de X_n. Par exemple, en 100 ans d'augmentation de 1%, on obtient $X_{100} = 2.7 X_0$.
L'hypothèse que les $X_{n+1} - X_n$ sont identiquement distribuées n'est pas crédible.

❷ On introduit la variable

$$Y_n = \ln\left(\frac{X_{n+1}}{X_n}\right).$$

On a

$$Y_n = \ln\left(1 + \frac{X_{n+1} - X_n}{X_n}\right).$$

Comme les taux de croissance relatifs sont supposés petits, on utilise l'approximation $\ln(1+u) \simeq u$. Ainsi,

$$Y_n = \ln\left(1 + \frac{X_{n+1} - X_n}{X_n}\right) \simeq \frac{X_{n+1} - X_n}{X_n}.$$

Il est alors raisonnable de supposer que les variables $(Y_n)_{n\geqslant 0}$ sont indépendantes et identiquement distribuées, avec, approximativement,

$$\mathrm{E}(Y_n) \simeq \frac{1}{100} \qquad \text{et} \qquad \sigma(Y_n) \simeq \frac{1}{200}.$$

Dans la suite, on adopte ces approximations.

❸ Posons

$$S_n = \sum_{k=0}^{n-1} Y_k = \sum_{k=0}^{n-1} \ln\left(\frac{X_{k+1}}{X_k}\right).$$

Par télescopage,

$$S_n = \ln\left(\frac{X_1}{X_0}\right) + \ln\left(\frac{X_2}{X_1}\right) + \cdots + \ln\left(\frac{X_n}{X_{n-1}}\right) = \ln\left(\frac{X_1}{X_0} \times \frac{X_2}{X_1} \times \cdots \times \frac{X_n}{X_{n-1}}\right) = \ln\left(\frac{X_n}{X_0}\right).$$

Ainsi,

$$X_n = X_0 e^{S_n}.$$

Les variables Y_n étant supposées i.i.d., on a

$$\mathrm{E}(S_n) \simeq \frac{n}{100} \qquad \text{et} \qquad \mathrm{Var}(S_n) \simeq \frac{n}{40000}.$$

Par conséquent,

$$\mathrm{E}(S_{100}) \simeq 1 \qquad \text{et} \qquad \sigma(S_{100}) \simeq \frac{1}{20}.$$

D'après le théorème central limite, S_{100} est approximativement distribuée selon une loi normale d'espérance 1 et de variance $\frac{1}{400}$. Un intervalle approximatif à 95 % pour S_{100} est donc

$$\left[1 - \frac{1.96}{20}, 1 + \frac{1.96}{20}\right].$$

En remplaçant 1.96 par 2, on obtient l'approximation

$$P(S_{100} \in [0.9, 1.1]) \simeq 0.95.$$

Comme $X_{100} = X_0 e^{S_{100}}$ et que la fonction exponentielle est strictement croissante,

$$P\left(X_0 e^{0.9} \leqslant X_{100} \leqslant X_0 e^{1.1}\right) \simeq 0.95.$$

Avec $X_0 = 100\,000$, on obtient

$$a_{100} = 100\,000 e^{0.9} \simeq 245\,960,$$

et

$$b_{100} = 100\,000 e^{1.1} \simeq 300\,417.$$

Finalement, un intervalle de prédiction approximatif à 95 % est

$$\boxed{[245\,960\,;\ 300\,417].}$$

Exercice 6 **☆ Intervalle de confiance ☆**

Soit $n \in \mathbb{N}$, supposé grand. On considère n variables aléatoires $X_1, \ldots, X_n$ i.i.d. telles que :

$$\mathrm{E}(X_k) = m \text{ inconnue} \qquad \text{et} \qquad \sigma(X_k) = 3.$$

On définit la moyenne empirique (variable aléatoire) :

$$\overline{X}_n = \frac{X_1 + \cdots + X_n}{n}.$$

Supposons qu'on observe les valeurs $x_1, \ldots, x_n$ telles que

$$\overline{x}_n = \frac{x_1 + \cdots + x_n}{n} = 10.$$

❶ **Test d'hypothèse :** Supposons que $m = 2$. Quelle serait alors la probabilité

$$P(\overline{X}_n \geq 10)\,?$$

Peut-on accepter l'hypothèse $m = 2$ à la lumière de cette observation ?

❷ **Hypothèse crédible :** Proposer une autre valeur de m pour laquelle la moyenne observée $\overline{x}_n = 10$ serait cohérente.

❸ **Intervalle de confiance à 95% :** En supposant que $\overline{X}_{100} = 10$ et $n = 100$, proposer un intervalle $[a_{100}, b_{100}]$ tel que

$$P(m \in [a_{100}, b_{100}]) \simeq 0.95.$$

Indication : utiliser l'approximation normale pour $\overline{X}_n$.

Solution :

Soient $X_1, \ldots, X_n$ i.i.d. tels que :

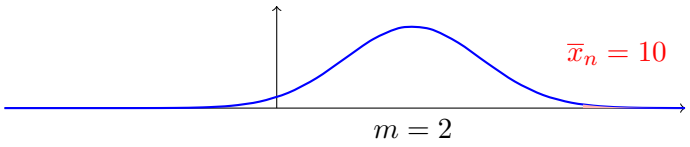
$$\mathbb{E}(X_k) = m \quad \text{(inconnue)}, \qquad \sigma = 3$$

On observe :

$$\overline{x}_n = 10$$

❶ Selon le TCL, pour un grand n, $\overline{X}_n$ suit approximativement une distribution normale avec une moyenne $\mu = \mathrm{E}(\overline{X}_n)$ et un écart type $\sigma = \frac{\sigma(X_k)}{\sqrt{n}}$.
Dans ce cas, puisque X_k a une moyenne $\mu = m = 2$ et un écart type $\sigma = \frac{3}{\sqrt{n}}$, nous avons :

$$\mu = 2 \qquad \text{et} \qquad \sigma = \frac{3}{\sqrt{n}} \qquad \Longrightarrow \overline{X}_n \approx \mathcal{N}\left(2, \frac{9}{n}\right)$$



Nous devons maintenant estimer la probabilité $P\left(\overline{X}_n \geqslant 10\right)$ sous l'hypothèse $m = 2$. Pour cela, nous allons standardiser la variable aléatoire $\overline{X}_n$:

$$Z_n = \frac{\overline{X}_n - \mu}{\sigma} = \frac{\overline{X}_n - 2}{\frac{3}{\sqrt{n}}} \approx \mathcal{N}(0,1)$$

Donc

$$P(\overline{X}_n \geq 10) = P\left(Z_n \geq \frac{8\sqrt{n}}{3}\right) = 1 - \phi\left(\frac{8\sqrt{n}}{3}\right)$$

Nous pouvons utiliser cette probabilité pour déterminer si l'hypothèse $m = 2$ est plausible. Si la probabilité est très faible, cela suggère que $m = 2$ est une mauvaise hypothèse. Si la probabilité est élevée, cela soutient l'hypothèse $m = 2$.
Or $\frac{8\sqrt{n}}{3}$ est énorme dès que n est grand. Donc

$$P(\overline{X}_n \geq 10) = P\left(Z_n \geq \frac{8\sqrt{n}}{3}\right) \approx 0$$

Conclusion : on rejette $m = 2$.

❷ **Valeur crédible**

$$m \approx \overline{x}_n = 10$$

❸ **Intervalle de confiance (95%) :**

$$\overline{X}_{100} \approx \mathcal{N}\left(m, \frac{9}{100}\right), \quad \sigma_{\overline{X}_{100}} = \frac{3}{\sqrt{100}} = 0.3 \qquad \Longrightarrow Z_{100} = \frac{\overline{X}_{100} - m}{0.3} \approx \mathcal{N}(0,1)$$

Un intervalle à 95% :

$$P(m \in [a_{100}, b_{100}]) = P\left(\overline{Z}_{100} \in \left[\frac{-b_{100} + 10}{0.3}, \frac{-a_{100} + 10}{0.3}\right]\right) \simeq 0.95$$

Donc

$$\frac{-b_{100} + 10}{0.3} = -1.96 \qquad \text{et} \qquad \frac{-a_{100} + 10}{0.3} = 1.96$$

D'où

$$IC_{95\%} = [10 - 1.96 \times 0.3,\ 10 + 1.96 \times 0.3] = [9.41,\ 10.59]$$

